

## דוח למידת מכונה – עבודה מס 2

מגיש: רועי הנדלר 208728337

בשביל לבחור את הקבועים הטובים ביותר לכל אחד מין האלגוריתמים, אני למעשה בנית פונקציית בדיקה - `find_best_parameters`.

בפונקציה זו אני מריץ את כל אחד מין האלגוריתמים במספרים וקבועים שונים. בסיום כל הרצה אני מדפיס את המידע על ההרצה – כלומר עם איזה קבועים התבצעה אותה הרצה, ובנוסף את תוצאות ההרצה (כלומר מה אחוז האלגוריתם). לסיום אני לוקח את הקבועים אשר הביאו את התוצאות הטובות ביותר בכל אחד מין אלגוריתמים.

תחילה נצרף כצילום את פונקציית הבדיקה `find_best_parameters`:

```
154
155 def find_best_parameters(X, y):
156     num_test = int(y.size * 0.2)
157
158     train_X, train_y = X[:-num_test, :], y[:-num_test]
159     test_X, test_Y = X[-num_test:, :], y[-num_test:]
160
161     print()
162     print("Testing KNN")
163     for k in [1, 2, 3, 4, 5, 6, 7, 8, 9, 10, 12, 14, 16, 18, 20, 25, 30, 35, 40, 50]:
164         model = KNN(train_X, train_y, k=k)
165         print(f"K={k}, result={test(model, test_X, test_Y)}")
166
167     print()
168     print("Testing Perceptron")
169     for eta in [0.1, 0.25, 0.5, 0.75, 1, 1.5, 2, 3, 4, 5]:
170         for epochs in [100, 250, 500, 1000, 1500, 2500, 3000]:
171             model = Perceptron(train_X, train_y, eta=eta, epochs=epochs)
172             print(f"eta={eta}, epochs={epochs}, result={test(model, test_X, test_Y)}")
173
174     print()
175     print("Testing SVM")
176     for eta in [0.1, 0.25, 0.5, 0.75, 1, 1.5, 2, 3, 4, 5]:
177         for lamda in [0.01, 0.025, 0.05, 0.075, 0.1, 0.15, 0.2, 0.3, 0.4, 0.5]:
178             for epochs in [100, 250, 500, 1000, 1500, 2500, 3000]:
179                 model = SVM(train_X, train_y, eta=eta, lamda=lamda, epochs=epochs)
180                 print(f"eta={eta}, lamda={lamda}, epochs={epochs}, result={test(model, test_X, test_Y)}")
181
182     print()
183     print("Testing PA")
184     for epochs in [100, 250, 500, 1000, 1500, 2500, 3000]:
185         model = PA(train_X, train_y, eta=eta, epochs=epochs)
186         print(f"epochs={epochs}, result={test(model, test_X, test_Y)}")
187
```

כעת הסביר את הפונקציה `find_best_parameters`. בשורה 156 אני למעשה מגדיר את `test` שלי להיות 20% מכלל המידע. בשורה 159 אני מגדיר את `train` שלי להיות בהתאם (20%, 80%). בשורה 163 אני מגדיר את `k` (המספר הקבוע) שאני רוצה לבדוק באלגוריתם KNN. בשורה 164 אני מריץ בלולאה את אלגוריתם KNN כאשר בכל ריצה של האלגוריתם אני משתמש בקבוע אחר. בסיום כל ריצה אני מדפיס למסך את התוצאה של האלגוריתם ובנוסף מציין עם איזה קבוע האלגוריתם רץ (ההדפסה מתבצעת בשורה 165). בשורה 169 אני מגדיר את `eta` (המספר הקבוע) שאני רוצה לבדוק באלגוריתם perceptron. בשורה 170 אני מגדיר את `epochs` (המספר הקבוע) שאני רוצה לבדוק באלגוריתם perceptron. בשורה 171 אני מריץ בלולאה את אלגוריתם perceptron כאשר בכל ריצה של האלגוריתם אני משתמש בקבוע אחר. בסיום כל ריצה אני מדפיס למסך את התוצאה של האלגוריתם ובנוסף מציין עם איזה קבוע האלגוריתם רץ (ההדפסה מתבצעת בשורה 172).

בשורה 176 אני מגדיר את eta (המספר הקבוע) שאני רוצה לבדוק באלגוריתם SVM.  
 בשורה 177 אני מגדיר את lamdan (המספר הקבוע) שאני רוצה לבדוק באלגוריתם SVM.  
 בשורה 178 אני מגדיר את epochs (המספר הקבוע) שאני רוצה לבדוק באלגוריתם SVM.  
 בשורה 179 אני מריץ בלולאה את אלגוריתם SVM כאשר בכל ריצה של האלגוריתם אני משתמש בקבוע אחר. בסיום כל ריצה אני מדפיס למסך את התוצאה של האלגוריתם ובנוסף מציין עם איזה קבוע האלגוריתם רץ (ההדפסה מתבצעת בשורה 180).  
 כמובן שאני מבצע הרצאה שמשלבת את כל אחד מן הנתונים – כלומר את כל האפשרויות הקיימות בין הקבועים שאני בודק, אני מבצע זאת על ידי for בתוך for.  
 בשורה 184 אני מגדיר את epochs (המספר הקבוע) שאני רוצה לבדוק באלגוריתם PA.  
 בשורה 185 אני מריץ בלולאה את אלגוריתם PA כאשר בכל ריצה של האלגוריתם אני משתמש בקבוע אחר. בסיום כל ריצה אני מדפיס למסך את התוצאה של האלגוריתם ובנוסף מציין עם איזה קבוע האלגוריתם רץ (ההדפסה מתבצעת בשורה 186).

כעת לאחר הרצת find\_best\_parameters אני קיבלתי את כלל התוצאות, וכך החלטתי על איזה קבועים להשתמש בכל אלגוריתם.

לסיום נצרף את התוצאות של הרצת פונקציית הבדיקה find\_best\_parameters:  
 אפשר לראות מהתוצאות המצורפות שיש טווחים של מספרים שלמעשה אנו מקבלים בהם את תוצאות מקסימליות ובאותו טווח הם גם דומות ביותר, לתוצאות אלא אני ביצעתי בדיקה ידנית – הרצתי את האלגוריתם עם מספר מספרים קבוצים שונים באותו טווח כדי לראות את המספר הטוב ביותר שאפשר להגדיר כקבוע.  
 יש לשים לב שאני משתמש באלגוריתם shuffled אשר היא רנדומלית, ולכן ריצה אחת יכולה לצאת בקצת יותר טוב מאחרת אבל כאשר נריץ שוב את אותם פרמטרים אנו מקבל תוצאות שונות במעט, זה קורה בגלל השימוש ברנדום.

```
Testing KNN
K=1, result=0.9166666666666666
K=2, result=0.8958333333333334
K=3, result=0.8958333333333334
K=4, result=0.9166666666666666
K=5, result=0.8958333333333334
K=6, result=0.8958333333333334
K=7, result=0.875
K=8, result=0.875
K=9, result=0.8541666666666666
K=10, result=0.875
K=12, result=0.8541666666666666
K=14, result=0.875
K=16, result=0.8541666666666666
K=18, result=0.8125
K=20, result=0.7708333333333334
K=25, result=0.7708333333333334
K=30, result=0.7708333333333334
K=35, result=0.7916666666666666
K=40, result=0.8125
K=50, result=0.7708333333333334

Testing Perceptron
eta=0.1, epochs=100, result=0.9375
eta=0.1, epochs=250, result=0.9375
```

eta=0.1, epochs=500, result=0.9375  
eta=0.1, epochs=1000, result=0.9375  
eta=0.1, epochs=1500, result=0.9583333333333334  
eta=0.1, epochs=2500, result=0.9375  
eta=0.1, epochs=3000, result=0.9583333333333334  
eta=0.25, epochs=100, result=0.9375  
eta=0.25, epochs=250, result=0.9583333333333334  
eta=0.25, epochs=500, result=0.9375  
eta=0.25, epochs=1000, result=0.9375  
eta=0.25, epochs=1500, result=0.9375  
eta=0.25, epochs=2500, result=0.9375  
eta=0.25, epochs=3000, result=0.9375  
eta=0.5, epochs=100, result=0.9375  
eta=0.5, epochs=250, result=0.9583333333333334  
eta=0.5, epochs=500, result=0.9583333333333334  
eta=0.5, epochs=1000, result=0.9375  
eta=0.5, epochs=1500, result=0.9375  
eta=0.5, epochs=2500, result=0.9375  
eta=0.5, epochs=3000, result=0.9583333333333334  
eta=0.75, epochs=100, result=0.9583333333333334  
eta=0.75, epochs=250, result=0.9375  
eta=0.75, epochs=500, result=0.9375  
eta=0.75, epochs=1000, result=0.9583333333333334  
eta=0.75, epochs=1500, result=0.9583333333333334  
eta=0.75, epochs=2500, result=0.9375  
eta=0.75, epochs=3000, result=0.9375  
eta=1, epochs=100, result=0.9375  
eta=1, epochs=250, result=0.9375  
eta=1, epochs=500, result=0.9375  
eta=1, epochs=1000, result=0.9583333333333334  
eta=1, epochs=1500, result=0.9375  
eta=1, epochs=2500, result=0.9375  
eta=1, epochs=3000, result=0.9375  
eta=1.5, epochs=100, result=0.9583333333333334  
eta=1.5, epochs=250, result=0.9375  
eta=1.5, epochs=500, result=0.9583333333333334  
eta=1.5, epochs=1000, result=0.9375  
eta=1.5, epochs=1500, result=0.9583333333333334  
eta=1.5, epochs=2500, result=0.9375  
eta=1.5, epochs=3000, result=0.9375  
eta=2, epochs=100, result=0.9375  
eta=2, epochs=250, result=0.9375  
eta=2, epochs=500, result=0.9375  
eta=2, epochs=1000, result=0.9375  
eta=2, epochs=1500, result=0.9375  
eta=2, epochs=2500, result=0.9375  
eta=2, epochs=3000, result=0.9375  
eta=3, epochs=100, result=0.9583333333333334  
eta=3, epochs=250, result=0.9583333333333334  
eta=3, epochs=500, result=0.9375  
eta=3, epochs=1000, result=0.9375  
eta=3, epochs=1500, result=0.9375  
eta=3, epochs=2500, result=0.9375  
eta=3, epochs=3000, result=0.9375  
eta=4, epochs=100, result=0.9375  
eta=4, epochs=250, result=0.9583333333333334  
eta=4, epochs=500, result=0.9375  
eta=4, epochs=1000, result=0.9375  
eta=4, epochs=1500, result=0.9583333333333334

```
eta=4, epochs=2500, result=0.9375
eta=4, epochs=3000, result=0.9583333333333334
eta=5, epochs=100, result=0.9375
eta=5, epochs=250, result=0.9375
eta=5, epochs=500, result=0.9375
eta=5, epochs=1000, result=0.9583333333333334
eta=5, epochs=1500, result=0.9375
eta=5, epochs=2500, result=0.9375
eta=5, epochs=3000, result=0.9375
```

#### Testing SVM

```
eta=0.1, lamda=0.01, epochs=100, result=0.9583333333333334
eta=0.1, lamda=0.01, epochs=250, result=0.9583333333333334
eta=0.1, lamda=0.01, epochs=500, result=0.9375
eta=0.1, lamda=0.01, epochs=1000, result=0.9583333333333334
eta=0.1, lamda=0.01, epochs=1500, result=0.9583333333333334
eta=0.1, lamda=0.01, epochs=2500, result=0.9583333333333334
eta=0.1, lamda=0.01, epochs=3000, result=0.9583333333333334
eta=0.1, lamda=0.025, epochs=100, result=0.9583333333333334
eta=0.1, lamda=0.025, epochs=250, result=0.9583333333333334
eta=0.1, lamda=0.025, epochs=500, result=0.9583333333333334
eta=0.1, lamda=0.025, epochs=1000, result=0.9583333333333334
eta=0.1, lamda=0.025, epochs=1500, result=0.9583333333333334
eta=0.1, lamda=0.025, epochs=2500, result=0.9583333333333334
eta=0.1, lamda=0.025, epochs=3000, result=0.9583333333333334
eta=0.1, lamda=0.05, epochs=100, result=0.9583333333333334
eta=0.1, lamda=0.05, epochs=250, result=0.9583333333333334
eta=0.1, lamda=0.05, epochs=500, result=0.9583333333333334
eta=0.1, lamda=0.05, epochs=1000, result=0.9583333333333334
eta=0.1, lamda=0.05, epochs=1500, result=0.9583333333333334
eta=0.1, lamda=0.05, epochs=2500, result=0.9583333333333334
eta=0.1, lamda=0.05, epochs=3000, result=0.9583333333333334
eta=0.1, lamda=0.075, epochs=100, result=0.9375
eta=0.1, lamda=0.075, epochs=250, result=0.9583333333333334
eta=0.1, lamda=0.075, epochs=500, result=0.9583333333333334
eta=0.1, lamda=0.075, epochs=1000, result=0.9375
eta=0.1, lamda=0.075, epochs=1500, result=0.9583333333333334
eta=0.1, lamda=0.075, epochs=2500, result=0.9583333333333334
eta=0.1, lamda=0.075, epochs=3000, result=0.9583333333333334
eta=0.1, lamda=0.1, epochs=100, result=0.9375
eta=0.1, lamda=0.1, epochs=250, result=0.9583333333333334
eta=0.1, lamda=0.1, epochs=500, result=0.9375
eta=0.1, lamda=0.1, epochs=1000, result=0.9583333333333334
eta=0.1, lamda=0.1, epochs=1500, result=0.9583333333333334
eta=0.1, lamda=0.1, epochs=2500, result=0.9583333333333334
eta=0.1, lamda=0.1, epochs=3000, result=0.9583333333333334
eta=0.1, lamda=0.15, epochs=100, result=0.9375
eta=0.1, lamda=0.15, epochs=250, result=0.9375
eta=0.1, lamda=0.15, epochs=500, result=0.9583333333333334
eta=0.1, lamda=0.15, epochs=1000, result=0.9583333333333334
eta=0.1, lamda=0.15, epochs=1500, result=0.9583333333333334
eta=0.1, lamda=0.15, epochs=2500, result=0.9583333333333334
eta=0.1, lamda=0.15, epochs=3000, result=0.9583333333333334
eta=0.1, lamda=0.2, epochs=100, result=0.9583333333333334
eta=0.1, lamda=0.2, epochs=250, result=0.9583333333333334
eta=0.1, lamda=0.2, epochs=500, result=0.9583333333333334
eta=0.1, lamda=0.2, epochs=1000, result=0.9583333333333334
eta=0.1, lamda=0.2, epochs=1500, result=0.9583333333333334
eta=0.1, lamda=0.2, epochs=2500, result=0.9583333333333334
```

[illegible]

[illegible]

[illegible]

[illegible]



[illegible]

[illegible]

[illegible]

[illegible]

[illegible]

[illegible]

[illegible]

```
eta=5, lamda=0.5, epochs=1500, result=0.9583333333333334  
eta=5, lamda=0.5, epochs=2500, result=0.9583333333333334  
eta=5, lamda=0.5, epochs=3000, result=0.9583333333333334
```

Testing PA

```
epochs=100, result=0.8541666666666666  
epochs=250, result=0.8333333333333334  
epochs=500, result=0.9375  
epochs=1000, result=0.9583333333333334  
epochs=1500, result=0.9583333333333334  
epochs=2500, result=0.8541666666666666  
epochs=3000, result=0.9791666666666666
```

כפי שניתן לראות באלגוריתם PA אנו מקבלים תוצאות מפוזרות מאוד, אך סביב הקבוע epochs=3000 אנו רואים שאפשר לקבל תוצות גבוהות לאלגוריתם. לכן הרצתי את אותו הפונקציה רק הפעם היא רצה בטווח של 3000 – 3100 כאשר היא לא מדלגת, כלומר עוברת קבוע קבוע (+1) לאחר ביצוע בדיקה זו קיבלתי שהקבוע הטוב ביותר הוא 3051